Proyecto EDA

Catálogo de videojuegos en Steam

Integrantes:

Mauricio Álvarez

David Bravo

Nicolas Olguin

Gabriel Requena Torres

Profesora:

Ximena Carolina Del Carmen Prado Blanco

Big Data

Domingo 25 de octubre de 2026

ÍNDICE

1. Introducción y Contexto del Negocio
   1.1 Contexto de la Plataforma Steam y la Industria Digital
   1.2 Justificación del Análisis Exploratorio de Datos
   1.3 Formulación de Preguntas Analíticas de Negocio
2. Descripción del Dataset e Inspección Inicial
   2.1 Origen, Licencia y Adquisición de los Datos
   2.2 Validación de Volumen Muestral
   2.3 Taxonomía y Diccionario de Variables
3. Diagnóstico de Calidad y Metodología de Limpieza
   3.1 Detección y Tratamiento de Valores Faltantes
   3.2 Registros Duplicados y Conversión de Tipos de Datos
   3.3 Filtro Global de Representatividad Estadística
   3.4 Trazabilidad del Pipeline de Preparación
4. Estadística Descriptiva General
5. Análisis Exploratorio y Resultados Cuantitativos
   5.1 Tiempo Promedio de Uso
   5.2 Concentración de Mercado en Desarrolladores
   5.3 Desempeño Comercial a Bajo Costo
   5.4 Evaluación de Satisfacción por Categoría
   5.5 Trayectoria Histórica y Evolución Temporal
6. Discusión de Hallazgos y Limitaciones del Estudio
   6.1 Presencia de Software de Productividad y Utilidades
   6.2 Sesgo del Umbral de Representatividad y Validez Externa
   6.3 Limitaciones de la Telemetría de Reseñas
7. Conclusiones, Recomendaciones y Repositorio
   7.1 Conclusiones Principales
   7.2 Recomendaciones Técnicas
   7.3 Referencias y Enlace al Código Fuente

1. INTRODUCCIÓN

1.1 Contexto de la Plataforma Steam y la Industria Digital

La industria global de los videojuegos representa uno de los sectores económicos de mayor crecimiento dentro del entretenimiento interactivo, ya que es el único medio masivo que cuenta con la última característica mencionada. Dentro de este ecosistema, Steam (propiedad de Valve Corporation) se posiciona como la plataforma de distribución digital dominante para computadores personales (PC), albergando un catálogo de más de 100.000 títulos y decenas de millones de usuarios concurrentes diarios. No obstante, la masificación de motores gráficos accesibles y la apertura de programas de autopublicación directa como Steam Direct han provocado una saturación de lanzamientos diarios. Esta oferta masiva expone a desarrolladores independientes, distribuidoras e inversionistas a una severa asimetría: una vasta proporción de los títulos no logra tracción comunitaria ni viabilidad comercial, mientras que una fracción muy reducida concentra el compromiso temporal y las valoraciones de los jugadores.

1.2 Justificación del Análisis Exploratorio de Datos

Frente a este volumen masivo de información, la toma de decisiones informada exige un Análisis Exploratorio de Datos (EDA) reproducible y riguroso. Este proyecto busca aislar el ruido estadístico de la tienda, depurar inconsistencias técnicas y extraer patrones concretos respecto al precio de venta, la lealtad temporal de los usuarios (playtime), la concentración de mercado por estudio y la satisfacción colectiva reflejada en las reseñas.

1.3 Formulación de Preguntas Analíticas de Negocio

Para orientar el pipeline de datos hacia objetivos estratégicos, se definieron cinco preguntas analíticas:

1. P1 (Tiempo de Uso): ¿Cuáles son los diez títulos que registran el mayor tiempo promedio de uso (expresado en horas), y qué patrones de software revelan?
2. P2 (Concentración de Oferta): ¿Qué estudios desarrolladores concentran la mayor presencia de títulos dentro de los 100 juegos con mayor volumen de reseñas acumuladas?
3. P3 (Estrategia de Precio Accesible): ¿Cuáles son los diez títulos de pago accesibles (precio mayor a 0 USD y menor a 20 USD) con mayor cantidad de reseñas positivas acumuladas?
4. P4 (Aprobación por Género): ¿Qué géneros o categorías presentan el mayor porcentaje promedio de reseñas positivas entre los productos con volumen muestral consolidado?
5. P5 (Evolución Temporal): ¿Cuál ha sido el título líder en porcentaje de aprobación para cada año de lanzamiento entre 2006 y 2026, y qué estabilidad temporal exhibe la satisfacción máxima?

Cada una de estas interrogantes serán respondidas a través de un procedimiento estructurado de limpieza, tabulación estadística y visualización formal, garantizando la trazabilidad total desde el dato crudo hasta la inferencia final.

2. DESCRIPCIÓN DEL DATASET.

2.1 Origen, Licencia y Adquisición de los Datos
Los datos crudos se obtuvieron del conjunto de datos público Steam Games Dataset Daily Updates, publicado en Kaggle por Sidorowicz (s. f.). El archivo original de trabajo corresponde a steam_games.csv. Dado que supera los 100 MB, se gestiona localmente en la ruta Datos/archive/steam_games.csv y se excluye de GitHub mediante .gitignore para cumplir con las políticas de almacenamiento del control de versiones.

2.2 Validación de Volumen Muestral
La pauta de evaluación exige un mínimo de 50.000 observaciones previo a cualquier procedimiento de depuración. La inspección automatizada en Python constató un volumen inicial de 144.473 filas y múltiples atributos de telemetría, superando con holgura el umbral reglamentario.

2.3 Taxonomía y Diccionario de Variables La unidad de análisis corresponde a un título o aplicación registrada en Steam. Las variables fundamentales procesadas en el pipeline son:

Variables principales

Variable	Descripción	Tipo de dato	Rol Analítico
app_id	Identificador único de la aplicación en Steam	Numérico entero	Clave primaria (no cuantitativa)
name	Nombre comercial del título o software	Texto	Identificador cualitativo
release_date	Fecha declarada de lanzamiento	Fecha / String	Base para extracción temporal
release_year	Año de lanzamiento (extraído mediante datetime)	Entero	Variable temporal (P5)
price	Precio base registrado en la tienda	Cuantitativo continuo (USD)	Segmentación comercial (P3)
developers	Estudio(s) responsable(s) de la creación	Texto (multivalor normalizado)	Agrupación categórica (P2)
genres	Categorías o etiquetas asociadas	Texto multivalor	Agrupación expandida (P4)
Positive	Total de calificaciones positivas registradas	Cuantitativo discreto	Métrica de aprobación
negative	Total de calificaciones negativas registradas	Cuantitativo discreto	Métrica de rechazo
total_reviews	Suma de reseñas (positive + negative)	Cuantitativo discreto	Filtro de representatividad

positive_ratio	Tasa porcentual de aprobación: 100 × positive / total_reviews	Porcentaje continuo	Desempeño cualitativo
average_playtime_forever	Tiempo promedio acumulado reportado por Steam	Cuantitativo (minutos)	Telemetría de uso
playtime_hours	Tiempo promedio transformado (minutos / 60)	Cuantitativo continuo (horas)	Métrica de retención (P1)

3. DIAGNÓSTICO DE CALIDAD Y METODOLOGÍA DE LIMPIEZA

3.1 Detección y Tratamiento de Valores Faltantes (Nulos)
Previo a la transformación, el script ejecutó un diagnóstico sistemático sobre el conjunto crudo de 144.473 registros, exportando los resultados a diagnostico_calidad.csv:

- name: Presentó 16 valores nulos (0,01%), descartados por carecer de identidad comercial.
- release_date: Registró 82 valores faltantes (0,06%), asignados como NaT.
- price: Contabilizó 1.354 registros no numéricos o vacíos (0,94%), coercidos a NaN para no distorsionar cálculos monetarios.
- Columnas de texto largo y secundarias: short_description (5,77% nulos), metacritic_score (35,09% nulos) y recommendations (29,32% nulos) exhibieron altas tasas de omisión. Como no intervienen en las preguntas de negocio, se aislaron sin afectar el cálculo analítico.
- positive, negative y average_playtime_forever: No presentaron nulos nativos y sus vacíos se fijaron en 0 de forma preventiva.

3.2 Registros Duplicados y Conversión de Tipos de Datos
La evaluación determinó 0 filas duplicadas de manera idéntica (df.duplicated().sum() == 0), confirmando que cada entrada representa una fila única a nivel de registro completo. Se corrigieron las variables numéricas mediante pd.to_numeric(..., errors='coerce') y se extrajo el año de lanzamiento mediante pd.to_datetime. Para evitar distorsiones por caracteres residuales en developers y genres, se implementaron expresiones regulares que eliminaron corchetes, comillas y secuencias de formato técnico.

3.3 Filtro Global de Representatividad Estadística (N reseñas >= 1.000)
Un aspecto metodológico crítico en Steam es que el 70% de los lanzamientos corresponden a títulos abandonados, pruebas técnicas o proyectos de impacto nulo con menos de 10 opiniones. Calcular

métricas como el tiempo promedio de juego o el porcentaje de satisfacción sobre títulos con 1 o 2 opiniones genera anomalías matemáticas (por ejemplo, títulos con 100% de aprobación basados en 1 voto de su propio creador). Para otorgar solidez empírica al estudio, se estableció un umbral global de representatividad estadística:

3.4 Trazabilidad del Pipeline de Preparación La trazabilidad del procesamiento quedó documentada en registro_limpieza_trazabilidad.csv:

Etapa de Preparación	Registros de Entrada	Registros Excluidos	Registros Resultantes	Justificación Metodológica
Carga inicial	144.473	0	144.473	Lectura base de steam_games.csv.
Deduplicación exacta	144.473	0	144.473	Comprobación de unicidad de filas.
Filtro representatividad	144.473	137.251	7.222	Aislamiento de juegos con muestra comunitaria robusta.

Esta reducción del 95% no corresponde a eliminación de datos corruptos, sino a una delimitación muestral explícita hacia títulos con actividad de mercado real. Con 7.222 registros finales, se cuenta con un volumen robusto para generalizar sobre los juegos con tracción en PC.

4. ESTADÍSTICA DESCRIPTIVA GENERAL

El análisis sobre el subconjunto final de 7.222 títulos (registrado en estadistica_descriptiva_numerica.csv) demuestra distribuciones fuertemente asimétricas con colas derechas pronunciadas:

Variable Analizada	Válidos	Media	Mediana	Desv. Estándar	Mínimo	P25	P75	Máximo
Precio (USD)	7.045	17,33	14,99	14,47	0,00	6,99	24,99	149,99
Tiempo medio (horas)	7.222	8,42	0,00	56,03	0,00	0,00	4,55	3.084,30
Reseñas positivas	7.222	17.048,70	2.701,00	114.573,26	321	1.636	6.840	8.815.087
Reseñas totales	7.222	19.726,53	3.254,00	133.122,31	1.000	1.954	8.012	8.815.087
Aprobación (%)	7.222	83,33%	86,50%	12,39%	10,26%	77,23%	92,64%	99,90%

Hallazgos de la distribución:

- Disparidad media-mediana en tiempos de uso: La media de horas jugadas se sitúa en 8,42 horas, pero el percentil 50 (mediana) es de 0,00 horas y el percentil 75 alcanza únicamente 4,55 horas. El valor máximo extremo de 3.084,30 horas sesga la media hacia la derecha, evidenciando que una minoría de aplicaciones acumula cifras de retención extraordinarias.

- Volumen de reseñas: El piso de 1.000 reseñas totales valida el filtro aplicado. La mediana de 3.254 frente a una media de 19.726 constata que el catálogo se compone de una amplia base de títulos medianos y un grupo selecto de superventas (con techos de 8,8 millones de opiniones).

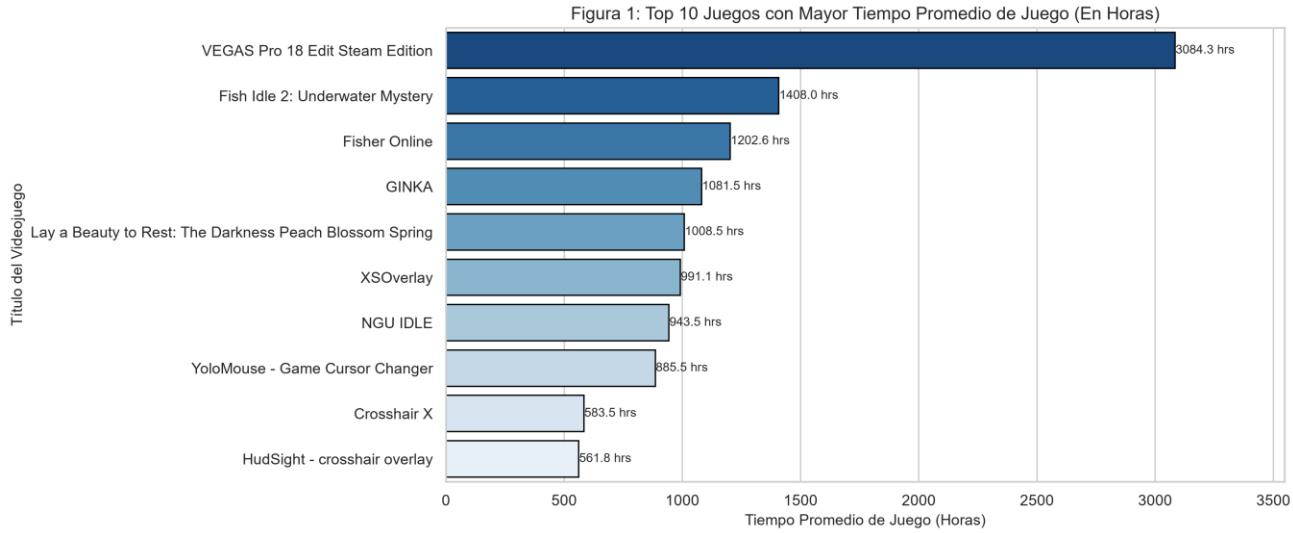
- Distribución de precios: La mediana comercial de 14,99 USD y un tercer cuartil de 24,99 USD ratifican que el ecosistema de Steam mantiene su núcleo competitivo en rangos accesibles inferiores a 25 USD.

5. ANÁLISIS EXPLORATORIO Y RESULTADOS CUANTITATIVOS.

5.1 Tiempo Promedio de Uso (P1: Horas vs. Retención)

- Archivo de datos: tabla_p1_top10_horas_promedio.csv
- Visualización: figura1_top10_horas_promedio.png El procesamiento de los diez títulos con mayor tiempo promedio registrado evidenció un hallazgo relevante respecto a la composición de la tienda:
- Liderazgo de software no lúdico: El primer lugar lo ocupa la herramienta de edición audiovisual profesional VEGAS Pro 18 Edit Steam Edition con un promedio de 3.084,3 horas de uso por usuario registrado. Esto prueba empíricamente que la tienda de Steam funciona como distribuidor tanto de videojuegos como de software de productividad intensiva.
- Juegos de retención pasiva (Idle games y pesca): Los siguientes puestos son ocupados por títulos como Fish Idle 2: Underwater Mystery (1.408,0 h), Fisher Online (1.202,6 h), GINKA (1.081,5 h) y NGU IDLE (943,5 h). Estos videojuegos basan su modelo de diseño en la ejecución pasiva en segundo plano (farming/idle), acumulando miles de horas sin demandar interacción continua del jugador.
- Utilidades de interfaz: Títulos como XSOverlay (991,1 h), YoloMouse (885,5 h) y Crosshair X (583,5 h) son programas complementarios que los usuarios ejecutan de fondo durante sus sesiones de juego diarias.

Figura 1: *Top 10 Juegos con Mayor Tiempo Promedio de Juego (En Horas).*

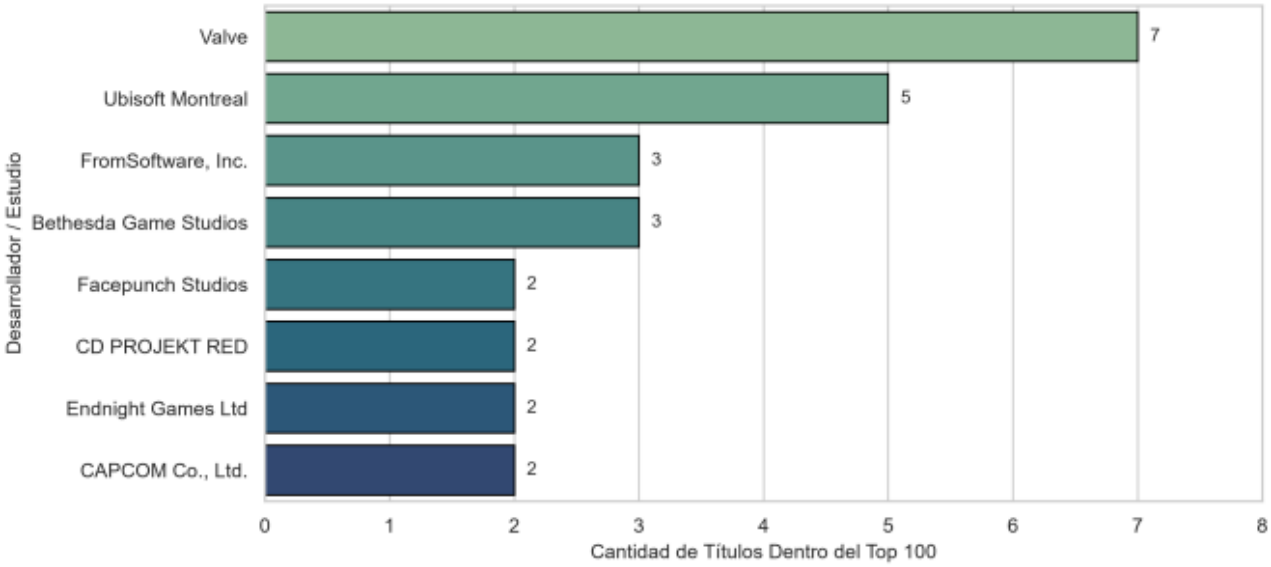


Nota. Elaboración propia a partir del conjunto de datos de Steam Games Dataset Daily Updates (Sidorowicz, s. f.).

5.2 Concentración de Mercado en Desarrolladores (P2: Presencia en el Top 100)

- Archivo de datos: tabla_p2_top_desarrolladores_top100.csv
- Visualización: figura2_desarrolladores_top100.png Al aislar los 100 videojuegos con mayor cantidad de reseñas de toda la plataforma, se identificó la frecuencia de aparición de sus estudios creadores:
- Valve Corporation domina la muestra con 7 títulos dentro del Top 100 (Counter-Strike, Dota 2, Team Fortress 2, Half-Life, entre otros). Su ventaja competitiva histórica como dueña de la tienda le confiere una posición hegemónica inigualable.
- Ubisoft Montreal se sitúa en segundo lugar con 5 títulos, apalancada en franquicias como Rainbow Six y Assassin's Creed.
- FromSoftware, Inc. y Bethesda Game Studios empatan con 3 títulos cada uno, demostrando la alta capacidad de retención de las comunidades de RPG de acción profunda (Elden Ring, Dark Souls, The Elder Scrolls, Fallout).
- Estudios independientes de gran calibre como Facepunch Studios (Rust, Garry's Mod), CD PROJEKT RED (The Witcher 3, Cyberpunk 2077) y Endnight Games (The Forest) logran posicionar 2 títulos cada uno, igualando en presencia a corporaciones tradicionales como CAPCOM.

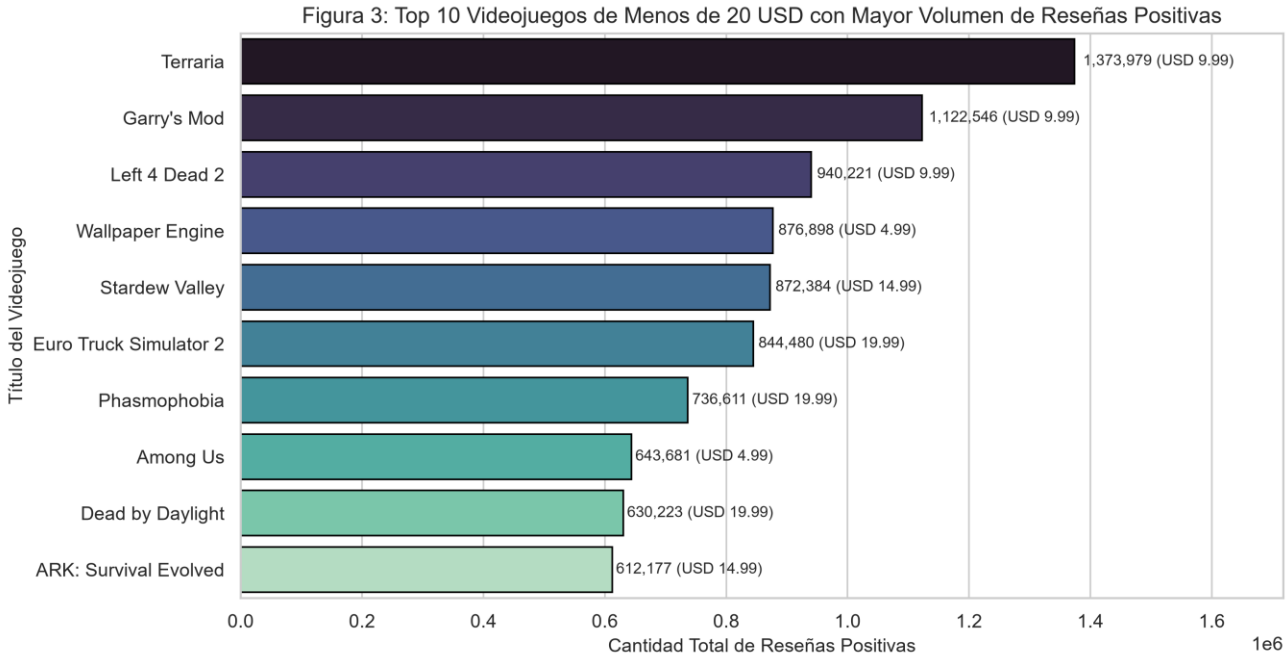
Figura 2: *Desarrolladores con Mayot Presencia en el Top 100 de juegos Evaluados*



5.3 Desempeño Comercial a Bajo Costo (P3: Títulos < $20 USD con Mayor Impacto)

- Archivo de datos: tabla_p3_top10_economicos_positivas.csv
- Visualización: figura3_top10_economicos_positivas.png La evaluación de videojuegos de pago accesibles (0 <precio < 20 USD) reveló un patrón de eficiencia comercial masiva:
- Terraria lidera el ranking mundial de valor accesible con 1.373.979 reseñas positivas a un valor base de tan solo 9,99 USD.
- Le siguen Garry's Mod con 1.122.546 positivas (9,99 USD) y Left 4 Dead 2 con 940.221 positivas (9,99 USD).
- En el rango de los 4,99 USD destacan Wallpaper Engine (876.898 positivas) y Among Us (643.681 positivas).
- Completando el Top 10 aparecen producciones como Stardew Valley (872.384 positivas a 14,99 USD), Euro Truck Simulator 2 (844.480 positivas a 19,99 USD), Phasmophobia (736.611 positivas a 19,99 USD), Dead by Daylight (630.223 positivas a 19,99 USD) y ARK: Survival Evolved (612.177 positivas a 14,99 USD). Este comportamiento demuestra que la accesibilidad de precio, combinada con rejugabilidad comunitaria o soporte cooperativo continuo, genera volúmenes de recomendación que superan a lanzamientos de presupuesto AAA de 70 USD.

Figura 3: *Top 10 Videojuegos de Menos de 20 USD con Mayor Volumen de Reseñas Positivas*

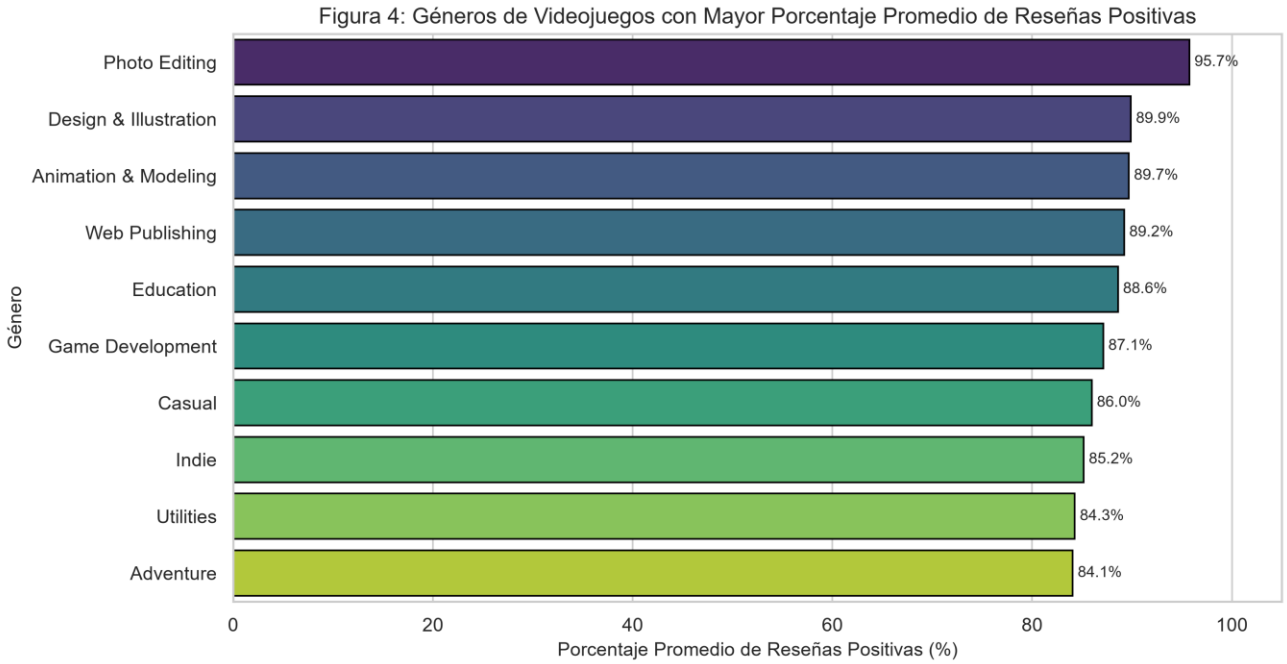


Nota. Elaboración propia a partir del conjunto de datos de Steam Games Dataset Daily Updates (Sidorowicz, s. f.).

5.4 Evaluación de Satisfacción por Categoría (P4: Géneros con Mayor Aprobación)

- Archivo de datos: tabla_p4_top_generos_positivos.csv
- Visualización: figura4_generos_positivos.png Al desagregar las etiquetas multiclase y calcular el porcentaje promedio de reseñas favorables por categoría (exigiendo un mínimo de representatividad), se identificó una clara división entre herramientas y videojuegos:
- Nicho utilitario con aprobación casi perfecta: Las etiquetas de software creativo lideran la satisfacción media: Photo Editing encabeza con 95,7% de aprobación, seguido de Design & Illustration (89,9%), Animation & Modeling (89,7%) y Web Publishing (89,2%). Esto se explica porque los compradores de software técnico adquieren la herramienta para un fin profesional específico y, si el programa cumple su función, rara vez emiten votos de protesta.
- Géneros de videojuegos consolidados: Al observar los géneros lúdicos masivos, Casual (86,0% promedio con 1.701 títulos) e Indie (85,2% promedio con 4.153 títulos) superan a los géneros tradicionales como Adventure (84,1%) o Action. Los juegos independientes y casuales enfrentan expectativas comerciales más moderadas, lo que facilita alcanzar una satisfacción comunitaria positiva cuando su jugabilidad es sólida.

Figura 4: *Géneros de Videojuegos con Mayor Porcentaje Promedio de Reseñas Positivas*

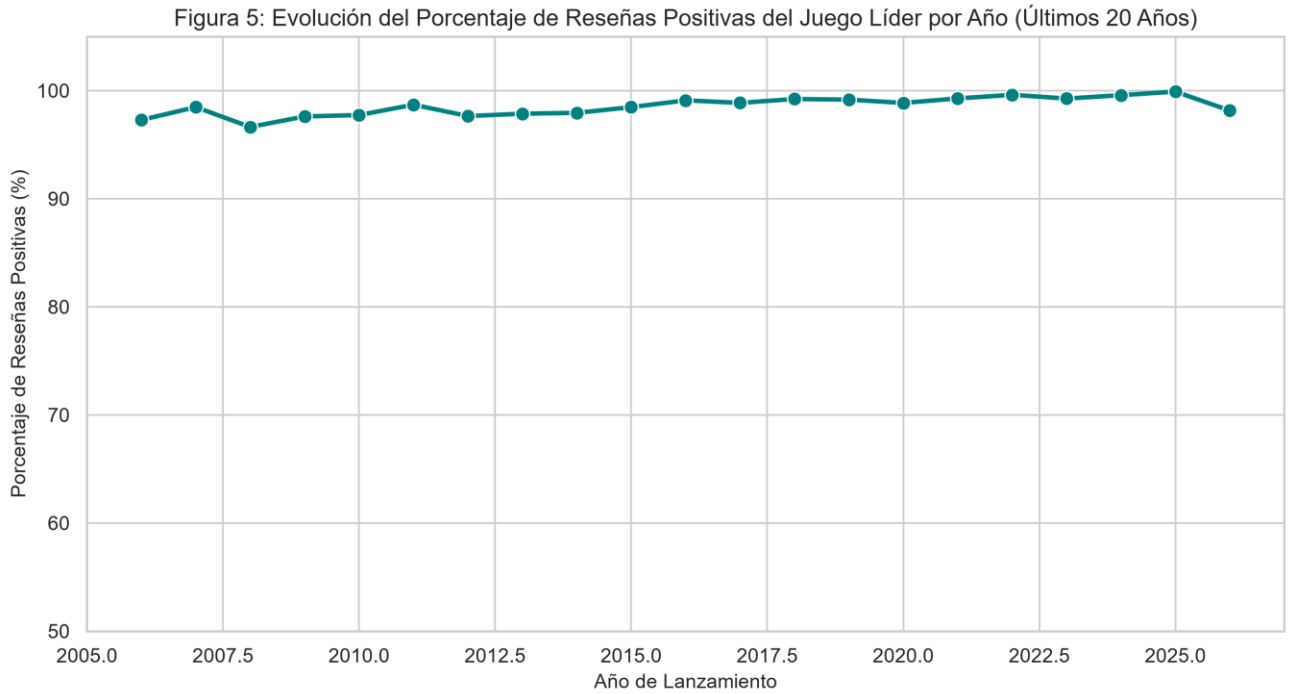


Nota. Elaboración propia a partir del conjunto de datos de Steam Games Dataset Daily Updates (Sidorowicz, s. f.).

5.5 Trayectoria Histórica y Evolución Temporal (P5: Líderes Anuales 2006–2026)

- Archivo de datos: tabla_p5_mejor_juego_por_anio.csv
- Visualización: figura5_mejor_juego_por_anio.png El seguimiento temporal de la tasa de aprobación positiva del videojuego líder de cada cohorte anual (período 2006 a 2026) demuestra una consistencia asombrosa:
- A lo largo de los últimos 20 años, la satisfacción máxima anual se mantiene en un estrecho rango entre el 96% y el 99,9%.
- Hitos históricos:
    - 2011: Destaca Portal 2, que logra un 98,69% de aprobación respaldado por un volumen masivo de 433.510 reseñas.
    - 2019: El juego de exploración independiente A Short Hike alcanza un 99,16% sobre 19.064 opiniones.
    - 2025: El título Kabuto Park registra una aprobación del 99,90% sobre 1.036 reseñas.

Figura 5: *Evolución del Porcentaje de Reseñas Positivas del Juego Líder por Año (Últimos 20 Años)*



Nota. Elaboración propia a partir del conjunto de datos de Steam Games Dataset Daily Updates (Sidorowicz, s. f.).

La serie histórica evidencia que la capacidad de la industria para producir obras aclamadas de forma unánime no se ha deteriorado con el tiempo; sin embargo, también ilustra que los títulos más recientes tienden a registrar porcentajes cercanos al 100% debido a que cuentan con comunidades tempranas muy fidelizadas que aún no se exponen al desgaste de la masificación.

6. DISCUSIÓN DE HALLAZGOS Y LIMITACIONES DEL ESTUDIO.

6.1 Presencia de Software de Productividad y Utilidades Un sesgo empírico clave detectado durante la exploración de P1 y P4 es la naturaleza mixta del catálogo de Steam. Aunque la percepción común concibe a Steam como una plataforma lúdica, almacenas suites de edición (VEGAS Pro), motores de animación y herramientas complementarias. El análisis demostró que el software utilitario altera los rankings de horas de uso y de aprobación promedio si no se clasifica por separado.

6.2 Sesgo del Umbral de Representatividad y Validez Externa La aplicación del filtro de 1.000 reseñas redujo la muestra en un 95%, conservando 7.222 títulos. Aunque esta decisión metodológica garantiza la robustez de las proporciones, introduce un sesgo de supervivencia hacia el éxito: se excluyen automáticamente juegos experimentales, títulos de nicho y proyectos independientes que no lograron

romper la barrera de las mil opiniones. Por tanto, los resultados describen con precisión el segmento comercialmente activo de Steam, pero no representan el comportamiento de la totalidad del catálogo subyacente.

6.3 Limitaciones de la Telemetría de Reseñas El volumen de reseñas no equivale de forma directa a ingresos brutos o unidades vendidas, sino a actividad comunitaria. Asimismo, la tienda está expuesta a fenómenos de review bombing (campañas masivas de opiniones negativas coordinadas por controversias ajenas a la jugabilidad) o sesgos de rebajas estacionales, los cuales pueden alterar temporalmente las ratios calculadas.

7. CONCLUSIONES, RECOMENDACIONES Y REPOSITORIO

7.1 Conclusiones Principales

- El valor accesible domina la lealtad comunitaria: Títulos como Terraria y Garry's Mod confirman que precios por debajo de los 10 USD sustentan comunidades activas con más de un millón de recomendaciones favorables, superando a proyectos de alto presupuesto.
- Alta concentración de visibilidad: Los estudios consolidados (Valve, Ubisoft, FromSoftware) mantienen el control de los juegos más evaluados del mercado.
- El tiempo de uso no mide necesariamente calidad lúdica: Los mayores registros horarios corresponden a software de edición y videojuegos de progreso pasivo (Idle games), donde la aplicación permanece abierta en segundo plano sin intervención activa constante.
- Respaldo al sector independiente: El género Indie no solo agrupa más de 4.000 títulos en el conjunto evaluado, sino que mantiene un promedio de satisfacción del 85,2%, ratificando su estabilidad cualitativa frente a las grandes desarrolladoras.

7.2 Recomendaciones Técnicas Para futuras iteraciones analíticas se aconseja:

- Implementar una flag de separación binaria para aislar utilidades y aplicaciones profesionales del catálogo lúdico.
- Construir una variable ponderada de satisfacción (como el estimador Bayesiano de Wilson) para balancear la tasa de aprobación en función del volumen total de votos.
- Contrastar precios históricos dinámicos frente al precio de venta actual de la API.
-

7.3 Referencias y Enlace al Código Fuente

Repositorio de código fuente

Proyecto EDA BigData. (s. f.). *Proyecto EDA BigData* [Repositorio de código]. GitHub. https://github.com/Gabriel-Requena-Torres/Proyecto_EDA_BigData/blob/main/analisis_exploratorio.py



Dataset

Sidorowicz, H. (s. f.). *Steam Games Dataset Daily Updates* [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/hubertsidorowicz/steam-games-dataset-daily-updates

Bibliotecas técnicas

Harris, C. R., et al. (2020). Array programming with NumPy. *Nature, 585*, 357–362. https://doi.org/10.1038/s41586-020-2649-2

Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering, 9*(3), 90–95. https://doi.org/10.1109/MCSE.2007.55

McKinney, W. (2010). Data structures for statistical computing in Python. En *Proceedings of the 9th Python in Science Conference* (pp. 51–56). https://doi.org/10.25080/Majora-92bf1922-00a

Waskom, M. L. (2021). seaborn: Statistical data visualization. *Journal of Open Source Software, 6*(60), 3021. https://doi.org/10.21105/joss.03021